

역기구학 2 일차 과제 1 레포트

로봇 예비단원 주호진

1) 용어 및 개념 정리

LIPFM: LIPM 에 플라이휠을 더한 모델, 질량 중심의 각운동량이 있다고 고려한 모델

CP(Capture Point, 캡처 포인트): 로봇의 CoM 이 수렴하는 지점, 로봇이 넘어지지 않고 멈추기 위해 다음 발을 디뎌야 하는 위치

SRB(single rigid body, 단일 강체 모델): 복잡한 구조를 하나의 커다란 덩어리로 단순화하여 다루는 모델

LQR(Linear Quadratic Regulator, 선형 이차 조절기): 제어 대상이 선형일 때 오차를 줄이는 것과 제어에 드는 비용을 최소화하는 제어 기법

자코비안: 로봇의 관절 공간과 손끝이나 몸통이 위치한 작업 공간 사이의 속도나 위치 관계를 연결해주는 1 계 편미분 행렬

CMP(중심 모멘트 피벗): 로봇의 CoM 을 지나면서, 현재 지면 반력의 방향과 평행하게 그은 직선이 바닥과 닿는 점

라플라스 변환: 시간 영역의 미분 방정식을 복소 주파수 영역의 대수 방정식으로 바꾸어주는 기법

MPC(Model Predictive control): 미래의 짧은 시간 동안 무슨 일이 일어날지 예측하고, 그에 맞춰 현재 내릴 최적의 제어 명령을 계산하는 제어 기법

QP 최적화(Quadratic Programming, 이차 계획법): *이차 형식의 목적 함수를 선형 제약 조건(1 차 제약 조건) 하에서 최소화하거나 최대화하는 최적화 기법

*이차 형식: 2 차항들로만 이루어진 식

CAM(중심 각 운동량): 어떤 물체나 입자계의 질량 중심(Center of Mass)을 회전축(기준점)으로 삼아 계산한 각운동량

centroidal 모델: 복잡한 다관절 로봇의 전신 동역학을 CoM 과 전체 운동량의 관점으로 단순화한 모델

centroidal moment: CoM 을 기준으로 로봇을 회전시키려는 회전력(토크)을 의미

deep q learning: *q learning 에 딥러닝을 합친 것. q learning 에서 q table 대신 딥러닝(인공신경망)을 사용함

*q learning: 모델 없이 학습하는 강화학습 알고리즘, 지금 행동에 대한 예측된 총 보상의 합을 가지고 있는 것을 q 값이라고 하고, 해당 q 값을 q table 에 저장하여 사용

DDPG(Deep Deterministic Policy Gradient) 알고리즘: *DQN 과 **DPG 를 합친 알고리즘. 어떠한 상태에서 DPG 를 통해 특정 행동을 뽑아내면 DQN 의 학습 원리를 적용하여 q 값을 계산하고, q 값을 참조하여 gradient 를 조정

*DQN: Deep Q learning 에 사용되는 인공신경망

**DPG: 특정 상태에서 확률적이 아닌 항상 같은 행동을 선택(결정론적(Deterministic) 선택)을 함. 행동에 대한 피드백을 받고, gradient 를 조정하는 알고리즘

RNN(Recurrent Neural Networks, 순환 신경망): 이전 시점의 정보를 다음 시점으로 전달하여 시간의 흐름에 따른 순차적 데이터를 처리할 수 있는 신경망

MLP(MultiLayer perceptron, 다층 퍼셉트론): 입력층 하나 이상의 은닉층, 출력층으로 이루어진 기본적인 인공신경망 구조

LSTM(Long Short Term Memory): RNN 의 장기 의존성 문제를 해결하기 위해 고안된 순환 신경망의 변형 모델. 입력, 망각, 출력 게이트를 두어 어떤 정보를 기억하고 어떤 정보를 망각할지 조절

sim-to-real: 시뮬레이션 환경을 실제 세계에 적용하는 것(simulation to real)

end-to-end: 입력부터 출력까지의 과정을 단계의 분할 없이 하나의 거대한 신경망이 처리하는 방식

HLC(High Level Control, 고수준 제어(플래닝)): 로봇에서 어디로 갈 것인지, 어떤 경로로 이동해야 하는지를 결정하는 제어. LLC 에 비해 넓은 시야를 가지고 긴 주기를 가짐

LLC(Low Level Control, 저수준 제어): HLC 가 준 목표 지점이나 궤적을 받아 실제 하드웨어를 움직임

SLIP(Spring Loaded Inverted Pendulum) 모델: 탄성 스프링이 달린 역진자 모델

attention 매커니즘: 입력된 정보들 중 어떤 정보가 더 중요하고 믿을 만한지를 AI 가 스스로 판별해 가중치를 주는 매커니즘

DTC(Deep Tracking Control) 알고리즘: 모델 기반 계획의 최적성과 딥러닝 강화 학습의 강인함을 결합한 하이브리드 제어 아키텍처

2) 논문 내용 정리

서론

휴머노이드의 제어 방법 2 가지

1. 모델 기반 제어 방법 수학적 모델을 기반으로 하기 때문에 안정성 보장, 모델 오차와 불확실성 있음
2. 강화 학습 기반 제어 방법 모델이나 제어 계획 방법 없이 학습 알고리즘과 환경만 있으면 됨, 시스템의 안정성을 보장할 수 없음

2장에서는 모델 기반 제어 방법 설명, 3장에서는 강화 학습 기반 제어 방법 설명, 4장(결론)에서는

앞으로 나가야할 방향 제시

본론(2 장)

1. LIPM 과 이에 기반한 하체를 이용한 보행 제어 방법

1.1 LIPM

1 일차 보고서에 정리했던 내용이 초반에 기재 질량 중심에 점질량으로 구성되어있다고 가정, 질량 중심은 움직이지 않는다고 가정하여 LIPM 모델을 적용함.

1.2 CoM 궤적 생성 및 하체를 이용한 ZMP 제어

실제 환경에서의 외란들이 CoM 과 ZMP 를 교란시켜 안정적인 보행을 어렵게 함(ex. 지면 착지 충격, 비평탄 지형으로 인한 외란). 따라서 CoM, ZMP 피드백 제어 방법들이 제안되기 시작됨.

1. 스프링 - 댐퍼 도립 진자 모델 사용
2. LQR(Linear Quadratic Regulator) 사용
3. 미리 설계된 ZMP 궤적을 고려한 preview control 기반, 오차 최소화를 위해 CoM 의 Jerk 계산
4. 자코비안을 이용하여 전신 관절의 움직임으로 발현하는 방법
5. LIPM 동역학 기반 CoM 움직임 조정 -> ZMP 제어
6. ZMP 를 직접적으로 조정하기 위해 양 발의 접촉 힘과 토크를 계산하여 제어하는 방법

1.3 LIPM 기반의 CP(Capture Point) 동역학

$$\xi_x = c_x + \frac{\dot{c}_x}{\omega}$$

CP = CoM + (CoM 의 속도 / ω)로 정의됨

ω 는 고유 진동수이며 (중력가속도/지면으로부터의 CoM 까지의 거리) $^{1/2}$

$$\dot{\xi}_x = \omega(\xi_x - z_x)$$

CoM-ZMP 동역학 식과 위 식의 시간에 대한 미분을 결합하면

$$CP \text{ 변화율} = \omega(CP - ZMP)$$

의 식이 나온다. CP 의 속도가 CP 와 ZMP 사이 거리에 비례하게 됨.

위 식을 통해 보행 주기 T 동안 ZMP 가 한 점에 위치하는 상수라고 가정하고, 현재의 CP, 현재의 보행시간 t 를 이용해 보행 스텝이 끝나는 지점의 CP 를 예측할 수 있음.

$$\xi_{x,T} = (\xi_x - z_x)e^{\omega(T-t)} + z_x$$


$$\text{보행 스텝이 끝나는 시점의 CP} = (CP - ZMP) * e^{\omega(T-t)} + ZMP$$

$$\xi_{x,T} = f_x + b_x = (\xi_x - z_x)e^{\omega(T-t)} + z_x$$

이렇게 정의된 보행 스텝이 끝나는 시점의 CP 는 다음 풋스텝 위치(f_x)와 CP 오프셋(b_x)의 합으로 정의될 수 있음.

여기서 b_x 는 보행 스텝이 끝나는 시점의 CP 와 다음 풋스텝의 위치 f_x 의 차이를 의미함.

1.4 하체를 이용한 CP 제어



LIPM 기반의 ZMP, CP 그리고 CoM 의 동역학 관계는 라플라스 변환으로 표현될 수 있음.

ZMP 제어 방식은 CoM 을 발산시킬 수 있는 불안정 동역학을 포함하고, CP 와 CoM 은 안정적인 동역학 관계임.

(CP 의 정의에서 CoM 을 기준으로 정리해봤을 때 x 의 계수가 - ω 이고, ω 는 항상 양수이므로 계수는 항상 음수가 됨. 미분방정식에서 계수가 음수 -> 시간이 흐를수록 시스템이 안정화된다는 뜻)

ZMP 를 제어 입력으로 하여 CP 를 안정적으로 제어한다면 CoM 은 항상 안정적임.

따라서 ZMP 를 이용하여 CP 를 제어하는 방법들이 제안되기 시작함.

1. CP 동역학을 기반으로 ZMP 조정을 통해 CP 를 안정적으로 제어하는 두 가지 보행 알고리즘을 제안
 - 1.1 미리 설계된 다음 풋스텝 위에 "참조 CP"를 위치시킨 후 현재 계산된 CP 가 참조 CP 를 추종하도록 하는 방법
 - 1.2 보행 스텝 동안의 CP 궤적을 미리 설계하고 그 궤적을 따라가는 방법
2. PID 제어 기반으로 ZMP 값을 피드백하여 CP 제어
3. MPC 의 비용 함수에 CP 오차 항을 정의하여, CP 제어를 위한 ZMP 입력을 계산
4. PID 의 P 제어 + MPC 최적화(2 번 + 3 번 째)

이러한 연구들은 CP 를 제어하기 위해 지지 다각형 내에 ZMP 를 자유롭게 움직이도록 조정하고, ZMP 제어에 자유도를 부여함으로써 외란에 유연하고 강건한 보행 성능을 보여줌.

2. 풋스텝 위치 및 스텝 시간 조정 제어

앞에서 풋스텝과 스텝 시간(주기)이 미리 주어졌을 때, 주어진 풋스텝을 기반으로 ZMP, CP 궤적을 설계하고 이를 추종하는 제어 방법들이 소개되었음.

그러나 풋스텝 위치 및 스텝 시간이 고정되어 있으면, 외란에 대한 유연성이 부족하고, 큰 외란을 극복할 때 제한적인 성능을 가짐.

이러한 점을 극복하기 위해 풋스텝 위치와 스텝 시간을 조정하는 알고리즘이 제안되기 시작함.

1. 보행 중 ZMP 궤적이 수정되어도 안정적인 CoM 궤적을 다시 그려내는 방법을 개발
2. 1 의 연구를 확장하여 보행 중 참조 CoM 속도와 참조 ZMP 궤적을 추종하기 위해 풋스텝 위치를 실시간으로 결정하는 방법을 제안
3. CP 오차를 보상하기 위한 추가 ZMP 입력을 계산하고, ZMP 입력이 제한되는 경우 풋스텝 위치가 CP 오차를 줄이는 방향으로 조정되는 방법을 제안
4. LIPM 외에 다른 모델을 이용한 풋스텝 조정 알고리즘들도 제안됨

위와 같이 스텝 위치를 조정하는 것은 MPC 를 이용해 많은 발전이 있었음. 그러나 스텝 시간을 MPC 를 이용해 최적화하는 것은 비선형성을 유발해 많은 계산량이 생기게 됨. 따라서 MPC 기반 스텝 시간 최적화의 구현은 최근에도 여전히 어려운 문제로 여겨짐.

MPC 최적화 기반 외에도 다양한 알고리즘들이 제안되었음.

1. 실시간 QP 최적화를 이용하여 CP 오프셋을 제어하기 위한 풋스텝 위치 및 스텝 시간 조정 알고리즘을 제안
2. 1 의 연구를 확장하여, 사전에 설정된 CP 오프셋을 맞추기 위해 ZMP 를 추가적인 최적화 변수로 고려하는 QP 알고리즘을 제안
3. 보행 중 발생하는 CP 에러의 크기와 방향에 따라 스텝 시간을 줄여 풋스텝 위치를 조정하는 휴리스틱 방법을 제안

이러한 QP 최적화 및 휴리스틱 기반의 방법들은 MPC 에 비해 미래의 상태를 고려하여 계산하지는 못하지만, 빠른 제어 주기로 알고리즘을 구동하여 외란에 대해 좋은 성능을 보여줌.

3. LIPFM 과 이에 기반한 CAM 제어

3.1 LIPFM

기존 하체 중심 보행 알고리즘이 발전함에 따라 고려되지 않았던 CAM 이 로봇의 균형 제어를 목적으로 고려되기 시작 따라서 상체 혹은 전신의 움직임을 이용한 CAM 제어 방법들이 제안되기 시작함.

1. 상체 혹은 전신의 움직임으로부터 생성되는 CAM 을 단순화된 모델로 다루기 위해 기존 LIPM 에 플라이휠을 추가한 LIPFM 을 제안

LIPFM 은 질량 중심에서의 회전이 추가되었기 때문에, LIPM 의 CoM-ZMP 동역학이 LIPFM 에서는 CoM 과 CMP 의 동역학 관계로 정의됨.

LIPFM 은 CoM 의 가속도가 ZMP 와 centroidal moment 로부터 결정됨. 따라서 CoM 의 가속도를 조정할 수 있는 추가적인 자유도가 생김.

centroidal moment 보다는 구하기 쉬운 centroidal moment 적분값인 CAM 을 사용함.

(힘을 적분하면 운동량인 것처럼, 토크를 적분하여 각운동량을 구함)

3.2 상체 혹은 전신을 이용한 CAM 제어

LIPFM 모델이 제안된 이후 CAM 제어 알고리즘들이 개발되기 시작됨.

보행 중 로봇의 CAM 을 0 으로 유지 + 외란에 대한 균형 제어를 목적으로 계산된 CAM 을 추가적으로 생성하는 연구들이 제안됨. 이때 휴머노이드가 무한히 회전할 수는 없기에, CAM 을 생성한 이후 초기 자세로의 복구 과정이 필요함.

1. 정해진 시간에 따라 로봇의 움직임을 통해 CAM 을 생성하고 다시 초기 자세로 복구하는 제어 프레임워크가 개발됨. 다만, 정해진 시간에 정해진 동작을 하기 때문에 다양한 외란에 유연하게 대처가 어려움
2. 1 의 단점을 극복하기 위해 로봇의 상태에 따라 CAM 제어를 수행하는 QP 최적화 기반 프레임워크 제안됨
3. 2 를 기반으로 CAM 생성과 자세 복구 제어의 우선 순위를 할당하는 계층적 QP 프레임워크를 제안함
4. LIPFM 외에 다른 모델을 이용한 CAM 프레임 워크도 제안됨

기존에는 CAM 기존 보행 알고리즘에서 고려되지 않았었지만, CAM 을 활용한 통한 제어 방법들이 보행에 더 안정적인 성능을 보여주는 결과를 가짐.

본론(3 장)

컴퓨터 그래픽스 분야와 사족 로봇 강화학습 연구 결과를 적용하는 경향이 있으므로 같이 소개됨.

1. end to end 강화 학습 기반 보행

구글 딥마인드에서 처음으로 연속 행동 공간에 강화학습 알고리즘을 적용한 연구를 발표함.

기존의 Deep Q learning 알고리즘의 문제점인 연속 행동 공간에 적용하기 어렵다는 문제를 해결하기 위해 DDPG 알고리즘을 개발함.

시뮬레이션 상에서 간단한 제어만 적용되었다는 한계점이 있지만 강화학습 알고리즘 기반의 end to end 방식으로 로봇을 제어할 수 있다는 가능성을 보여줌.

컴퓨터 그래픽스 분야에서는 물리 시뮬레이션 환경에서 자연스러운 동작을 하기 위해 강화 학습에 인간의 모션 캡처 데이터를 활용함.

1. 인간의 모션 캡처 데이터를 캐릭터가 따라하도록 하는 보상 함수를 설계
2. 1 과 유사하게 로봇이 참고 동작을 모방하도록 보상 함수를 제공하여 *Cassie 로봇이 물리 시뮬레이션에서 강화 학습을 기반으로 보행하는 결과를 발표
*Cassie 로봇: 애질리티 로보틱스의 이족보행 로봇

3. 다음 해에는 2 와 동일한 연구 그룹에서 실제 Cassie 로봇에서도 강화 학습 기반 보행 제어기를 적용할 수 있음을 실험적으로 보임

초기 보상 함수로 제어 정책을 학습한 후, 부족한 부분을 보완하도록 보상 함수를 추가하여 다시 학습함. 이때 이전에 학습한 정책의 행동을 잊지 않도록 모방 학습과 강화 학습을 동시에 진행하며 제어 정책을 다듬어가는 방식을 도입

위 연구 결과에 힘입어 실제 Cassie 로봇을 활용한 강화 학습 기반 보행 연구가 활발히 수행됨

1. MLP 가 아닌 RNN 계열의 LSTM 모델을 사용. RNN 네트워크가 강인한 sim-to-real 성능을 보여줌. 그러나 참조 모션 데이터를 하나만 사용하여 학습했기 때문에 같은 스타일의 보행만 할 수 있다는 한계점이 있음

2. 다음 해 1 과 동일한 연구 그룹에서 이족 보행 로봇의 보행 주기를 변화시킬 수 있는 학습 방법을 제안. 보행 제어를 통해 다양한 동작을 하나의 네트워크로 수행할 수 있음을 보여줌

3. 다양한 보행 데이터 라이브러리를 이용하여 Cassie 로봇에 전후, 좌우, 회전 보행, 높낮이 명령이 가능하도록 학습시킴

Cassie 로봇이 강화 학습 기반 보행 제어 연구에 많이 사용된 이유는 저감속비 구동기가 sim-to-real 에 유리하기 때문임. 그럼에도 불구하고 고감속비 구동기 휴머노이드 로봇 플랫폼을 이용한 강화 학습 기반 보행 연구들도 일부 수행되었음.

2. 계층적 구조의 강화 학습 기반 보행

보편적인 end-to-end 형식 외에 기존 모델 기반 제어기의 계층적 구조를 모방 및 활용한 강화 학습 기반 보행 연구를 소개함.

1. DeepLoco

LLC 와 HLC 로 계층 구성. LLC 는 휴머노이드 로봇이 레퍼런스 모션을 모방하면서 주어진 풋스텝 위치에 발을 놓도록 학습. HLC 는 로봇의 정보와 주변 지형 정보를 입력받아 로봇이 밟아야 할 풋스텝 위치를 출력하도록 학습

2. 모델 기반 플래닝 방법과 강화 학습 기반 LLC 를 계층적으로 설계

모델 기반 플래너는 SLIP 모델을 사용. 명령 속도로부터 로봇의 몸통과 두 발의 위치 및 속도, 관절의 위치를 계산. 강화 학습 기반 제어기는 플래너에서 나온 발 위치를 추종하도록 학습, 네트워크 제어기는 플래너에서 나온 목표 관절 각도의 변화를 출력

3. 강화 학습 기반 플레너와 모델 기반 제어기 계층 구조 제안

강화 학습 기반 플레너는 로봇의 상태와 명령을 바탕으로 양 발의 궤적을 결정.
모델 기반 제어기는 플레너에서 계산된 발의 궤적을 바탕으로 관절 토크 명령을 계산

모델 기반 방법과 강화 학습 기반을 같이 사용할 경우 빠르고 안정적인 학습이 가능함. 모듈 간 주고받는 정보가 공간상의 로봇의 목표 궤적이기 때문에, 이 정보를 사람이 이해하고 해석할 수 있는 장점이 있음. 그러나 별도 모델 기반 알고리즘을 구현해야 하기 때문에 많은 시간이 소요될 수 있고, 구조 특성 상 강화 학습 기반 제어기 성능이 구조적으로 제한된다는 한계점 존재함.

3. 지형 정보를 이용한 강화 학습 기반 보행

여러 연구를 통해 강화 학습 기반 보행 제어기에 지형 정보를 제공할 경우 로봇이 다양한 험지를 극복할 수 있음이 시뮬레이션을 통해 증명됨. 그러나 실제 로봇에서의 지형 정보 측정값은 시뮬레이션과는 다르게 많은 잡음과 측정 오차가 발생하기 때문에, 실제 로봇이 측정한 지형 정보를 활용하여 강화 학습 기반 보행 제어를 구현하는 것은 어려움.

1. 라이다 센서로 지형 정보를 측정했을 때 정돈된 실내 환경임에도 불구하고 시뮬레이션 값과 차이가 발생하여 실제 로봇에서의 최대 속도와 안정성이 시뮬레이션에서보다 감소함을 보고

2. 사족 로봇에서 위의 문제를 해결하기 위해 *belief encoder 를 도입.

*belief encoder: 로봇의 센서 정보와 지형 정보를 입력받아 attention 매커니즘을 통해 지형 정보의 신뢰성을 판별하고 해당 지형 정보를 사용할지에 대한 여부를 결정.

3. DTC 알고리즘 제안 비전 센서 기반으로 험지에서 기구학 및 동역학적으로 가능한 로봇의 전신 궤적을 계산하고 이를 강화학습 기반 알고리즘로 추종하는 제어를 수행

4. 이족 로봇을 시뮬레이션 학습 단계에서 로봇의 비전 정보로부터 지형 정보를 추정 후 이를 입력으로 제공함.

4 의 경우 비전 센서의 심각한 오류에 대응하기 힘들고, 정돈된 실내 환경에서만 검증됐다는 한계점이 있지만, 실제 로봇에서 지형 정보를 이용한 강화 학습 보행 연구가 시작됐다는 의의를 지님.

4 장(결론)

2 장 정리

최근 모델 기반 보행 알고리즘들은 ZMP, CAM, 풋스텝 조정 제어들을 MPC 최적화로부터 한 번에 통합하는 방법들이 많이 제안되고 있음. 또한 기초적인 LIPM 뿐만 아니라 다양한 모델을 이용한 MPC 기반 보행 알고리즘들이 많이 개발되고 있음 복잡한 모델을 사용하거나 필요한 최적화 변수들이 늘어날 수록 계산에 많은 시간이 소요됨. 그렇기에 어떤 모델을 사용하는 것이 최선인지, 많은 계산량은 어떻게 줄여나갈지에 대한 문제들은 여전히 해결해야 할 과제임.

3 장 정리

강화 학습 기반 보행 제어는 안정적인 학습이 가능하고 중간 정보를 해석할 수 있음. 그러나 보행 알고리즘 개발이 필요하고, 학습 제어기 성능이 구조적으로 제한될 수 있다는 단점이 있음. 하지만 사족 보행 연구에서 이러한 문제들이 해결되는 모습을 보이고 있으며, 이족 보행 연구에도 적용되어 휴머노이드까지 적용될 날이 머지 않았다고 예상됨.

최종 정리

사족 보행에서는 강화 학습 기반의 제어가 모델 기반 제어보다 높은 안정성과 보행 성능을 보여주고 있음. 그러나 균형 유지가 중요한 휴머노이드 보행(2 족 보행)에서는 목적에 따라 적합한 제어 방법이 달라지며, 두 방법 중 어떤 방식을 선택할지를 결정하는 것도 어려운 문제임. 따라서 휴머노이드의 보행 연구는 특정 제어 방법을 사용하기보다, 두 가지 방법을 결합한 형태의 보행 제어로 발전될 것으로 전망함.